Experimento Prático
Quando os dados não rotulados ajudam?

Objetivo: Investigar, sobre partições comparáveis, se e quando dados sem rótulos melhoram a classificação; identificar os mecanismos de cada método, seus riscos e seus custos. As atividades retomam os slides sobre pseudo-rotulação, múltiplas visões, propagação em grafos e ruído em sementes.

FLUXO DE REALIZAÇÃO DA ATIVIDADE

Organização	Orientação
Formato	Duplas; Python em Jupyter/Colab; entregar este checklist preenchido.
Mínimo para concluir	Etapas 0–4, matriz comparativa e conclusão; etapas 5–6 como aprofundamento.
Evidência obrigatória	Para cada método: configuração, F1-score no mesmo teste, duração aproximada, evidência gráfica/tabela e resposta interpretativa.

1 | ESCOLHA DA BASE E PROTOCOLO EXPERIMENTAL

Escolha uma base tabular de classificação e faça o download no repositório de origem. **Sugestão principal**: *Wine* (UCI, 178 amostras, 13 atributos, três classes). **Alternativa**: *Breast Cancer Wisconsin Diagnostic* (UCI, 569 amostras, 30 atributos, duas classes). Outros conjuntos do Kaggle ou Zenodo são válidos se houver descrição, licença e procedência verificáveis.

Wine: https://archive.ics.uci.edu/dataset/109/winedataset | **Breast Cancer**: https://archive.ics.uci.edu/dataset/17/breast-cancer-wisconsin-data-set

☐ Registrar título, URL, número de amostras, atributos, classes, distribuição das classes e eventuais valores ausentes.

☐ Reservar 20% para TESTE (*random_state*=73); o restante será somente treino. Não consultar o teste durante o ajuste.

☐ Dentro do treino, revelar inicialmente 10% dos rótulos por classe (L); ocultar os demais (U), codificando-os como −1. Guardar os rótulos reais de U exclusivamente para auditoria posterior.

☐ Padronizar os atributos com *StandardScaler* ajustado SOMENTE no treino e aplicado ao teste. Usar as MESMAS partições, sementes e atributos em todos os métodos.

☐ Calcular F1-score e acurácia no teste; bem como a matriz de confusão.

PERGUNTA: Por que utilizar as mesmas amostras L, U e teste é indispensável para uma comparação justa?

2 | REFERÊNCIA: SUPERVISIONADO COM POUCOS RÓTULOS

Pergunta exploratória: qual desempenho é possível obter sem explorar U? Este resultado constitui a referência obrigatória (*baseline*) para interpretar as próximas etapas.

☐ Treinar *LogisticRegression*(*max_iter*=1000) usando somente L separado para o treino.

☐ Avaliar F1-score e acurácia exclusivamente em L[X, y]; registrar tempo de treinamento.

PERGUNTA Quanto desempenho foi perdido ao reduzir a disponibilidade de rótulos?

3 | SELF-TRAINING: O MODELO PODE ENSINAR A SI PRÓPRIO?

Mecanismo: um classificador gera pseudorrótulos para U e incorpora predições suficientemente confiantes ao treinamento. O limiar τ controla a entrada de novos exemplos, mas confiança alta não garante correção.

☐ Executar *SelfTrainingClassifier*(*LogisticRegression*(*max_iter*=1000), *threshold*=0.75, *max_iter*=10) com X e y da base de treino.

☐ Repetir alterando threshold para 0.60 e 0.95; registrar F1-score, número de iterações e quantidade de pseudorrótulos incorporados.

☐ Auditar pseudorrótulos aceitos comparando-os, apenas na análise, com os rótulos reais previamente ocultados de U.

Limiar τ	F1-score teste	Aceitos / U	Precisão dos aceitos	Tempo (s)
0,60				
0,75				
0,95				

Perguntas:

- Aumentar o limiar sempre elevou a qualidade dos pseudorrótulos? O que aconteceu com a cobertura?
- Compare Self-Training e supervisionado restrito: U ajudou? Em qual condição poderia piorar?

4 | CO-TRAINING: DUAS VISÕES COMPLEMENTARES COOPERAM?

Mecanismo: dois modelos utilizam conjuntos distintos de atributos e fornecem pseudorrótulos um ao outro. Aqui vamos implementar uma versão simplificada, não uma reprodução integral do algoritmo original.

☐ Dividir os atributos em visões A e B (por exemplo, índices pares e ímpares); verificar se cada visão, isoladamente, carrega informação útil sobre a classe.

☐ Treinar um classificador logístico com L em cada visão; avaliar ambos no mesmo teste.

☐ Executar 3 rodadas: cada modelo seleciona, dentre U ainda não incorporado, até 5 exemplos com confiança ≥ 0,85; seus pseudorrótulos são adicionados apenas ao treino do OUTRO modelo.

☐ Se ambos propuserem rótulos divergentes para uma mesma amostra, não incorporar essa amostra na rodada; evitar que o mesmo exemplo seja incorporado duas vezes.

☐ Avaliar os dois modelos e comparar o melhor deles com a referência; registrar número de exemplos transferidos, desacordos e erros auditados.

Perguntas:

- As visões eram complementares ou uma delas era tão fraca que transferiu informação inadequada?
- Por que usar duas visões não elimina necessariamente o viés de confirmação?

Implementação orientada: Crie conjuntos rotulados LA e LB separados, inicialmente iguais ao L já trabalhado; a cada rodada, faça predict_proba de cada visão sobre índices ainda não utilizados, filtre por confiança e atualize apenas o conjunto rotulado do modelo oposto. Nunca use rótulos verdadeiros de U no treinamento.

5 | LABEL PROPAGATION: QUANDO A GEOMETRIA SUBSTITUI A CONFIANÇA?

Mecanismo: estabelece um grafo de similaridades entre amostras de L ∪ U e difunde rótulos pelos vizinhos. É particularmente ilustrativo para inferência sobre os nós conhecidos no grafo; a avaliação abaixo mantém o teste independente.

☐ Treinar *LabelPropagation*(*kernel*="knn", *n_neighbors*=5) com L[X, y].

☐ Repetir com k=3 e 15 e avaliar no mesmo X (a predição do *scikit-learn* para novas amostras é baseada nos pontos ajustados; isso não transforma o mecanismo central em treinamento indutivo convencional).

☐ Visualizar com t-SNE e PCA, apenas para fins descritivos, a distribuição 2D de L e U e os rótulos inferidos no treino.

k vizinhos	F1-score teste	Acertos nos rótulos ocultos de U	Tempo (s)
3			
5			
15			

Perguntas:

- O que muda quando k é alterado e o grafo passa a ligar amostras potencialmente de classes diferentes?
- Qual informação conduz a classificação em *Self-Training* e em *Label Propagation*, respectivamente?

6 | LABEL SPREADING: E SE UMA SEMENTE ESTIVER ERRADA?

Mecanismo: difusão em grafo com afinidade normalizada e relaxamento dos rótulos iniciais (*soft clamping*). A flexibilidade não garante identificar ou corrigir toda anotação errada.

☐ Rodar *LabelSpreading*(*kernel*="knn", *n_neighbors*=5, *alpha*=0.2) com rótulos corretos. Comparar com Label Propagation.

☐ Introduzir deliberadamente erro em 1 ou 2 rótulos de L, trocando-os por outra classe. Não modificar U nem o teste. Repetir ambos os métodos no MESMO cenário perturbado.

☐ Repetir *Label Spreading* com alpha=0.2 e 0.8; registrar alterações em F1-score e nas predições das sementes corrompidas.

Cenário	Propagation F1	Spreading α=0,2 F1	Spreading α=0,8 F1
Sementes corretas			
1–2 sementes alteradas			

Perguntas:

- Qual método foi mais sensível ao ruído? O resultado observado confirma ou contraria a hipótese inicial?
- O que é e por que "*soft clamping*" não significa corrigir rótulos automaticamente?

7 | DESAFIO DE ESTRESSE: QUANDO MAIS U ATRAPALHA?

☐ Repetir baseline, *Self-Training* e um método de grafos para 5%, 10% e 20% de rótulos disponíveis, usando divisões estratificadas e mesmo teste. Construir curva F1-score × número de rótulos.

☐ Criar perturbação somente em U (ex.: adicionar ruído gaussiano moderado às características de 20% de U), mantendo L e teste intactos; reexecutar os métodos. Justificar que a perturbação simula alteração de distribuição, não novos rótulos.

☐ Se houver tempo, repetir com sementes 21, 42 e 84; apresentar média ± desvio-padrão, evitando conclusões de uma única execução.

PERGUNTA A inclusão de U produziu benefício consistente ou dependeu de quantidade de rótulos, qualidade de U e geometria?

FOLHA DE SÍNTESE | COMPARAÇÃO ENTRE PARADIGMAS

Preencha após executar os experimentos. Evite classificar um método como universalmente superior: a comparação deve referir-se ao conjunto de dados e às condições efetivamente testadas.

Estratégia	Informação de U explorada	Principal benefício observado	Limitação/risco identificado
Supervisionado (L)	Não utiliza U		
Self-Training	Confiança e pseudorrótulos		
Co-Training	Troca entre duas visões		
Label Propagation	Conectividade do grafo		
Label Spreading	Difusão + flexibilidade nas sementes		

Resultados consolidados no mesmo teste

Modelo / configuração escolhida	F1-score	Acurácia	Tempo (s)	Observação
Supervisionado — somente L				
Supervisionado — todos os rótulos				
Self-Training				
Co-Training — visão A/B				
Label Propagation				
Label Spreading				

Perguntas:

- Qual técnica apresentou a maior economia potencial de rótulos para um desempenho semelhante ao supervisionado?
- Qual técnica exige uma hipótese sobre a estrutura do dado (vizinhança, grupos ou visões complementares) mais difícil de justificar nesta base?
- Em um conjunto médico com laudos escassos e anotações possivelmente ruidosas, quais métodos investigaria primeiro? Quais controles adicionais seriam indispensáveis?
- Como distinguir melhoria real de desempenho de vazamento de dados, acaso estatístico ou teste usado na seleção de parâmetros?